

ETF 가격 방향성 예측을 위한 그래프 구조 학습 기반 신경망† (Graph Structure Learning-Based Neural Network for ETF Price Movement Prediction)

요약 상장지수펀드(ETF)는 특정 지수를 추종하는 인덱스 펀드로, 개별 종목에 대한 위험도 및 운용보수가 낮다는 특징을 가지고 있다. ETF 예측을 위해 다양한 방법들이 개발되었으며 최근 인공지능 기반 기술들이 개발되고 있다. 대표적인 방법은 시계열 기반 인공지능망을 활용하여 ETF의 가격 방향성을 예측하는 것이다. 이는 ETF의 과거 가격 정보들을 효과적으로 반영하여 ETF의 등락을 예측할 수 있다는 장점이 있다. 하지만 개별 ETF의 과거 정보만 사용할 뿐 서로 다른 ETF 간의 관계를 반영하지 못하는 한계점을 지닌다. 이러한 문제를 해결하기 위해 본 논문에서는 ETF 간의 관계를 반영할 수 있는 모델을 제안한다. 제안 모델은 그래프 구조 학습을 통해 다양한 ETF 간의 관계를 표현하는 그래프를 추론하고, 이를 기반으로 그래프 신경망 모델을 통해 ETF 가격 방향성을 예측한다. 실험을 통해, 제안 모델이 개별 ETF 정보만 사용한 시계열 모델보다 우수한 예측 성능을 보이는 것을 확인하였다.

키워드 : ETF 방향성 예측, 그래프 구조 학습, 그래프 신경망, 심층학습

Abstract: Exchange-Traded Funds (ETFs) are index funds that mirror particular market indices, usually associated with their low risk and expense ratio to individual investors. Various methods have emerged for accurately predicting ETF price movements, and recently, AI-based technologies have been developed. One representative method involves using time-series-based neural networks to predict the price movement of ETFs. This approach effectively incorporates past price information of ETFs, allowing the prediction of their movement. However, it has a limitation as it only utilizes historical information of individual ETFs and does not account for the relationships and interactions between different ETFs. To address this issue, we propose a model that can capture relationships between ETFs. The proposed model uses graph structure learning to infer a graph representing relationships between ETFs. Based on this, a graph neural network predicts the ETF price movement. The proposed model demonstrates superior performance compared to time-series-based deep-learning models that only use individual ETF information.

Keywords : ETF prediction, graph structure learning, graph neural networks, deep learning

논문접수 : 2023년

(Received)

논문수정 :

(Revised)

심사완료 :

(Accepted)

Copyright©2023 한국정보과학회 : 개인 목적이거나 교육 목적인 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.
정보과학회논문지 제 권 제 호 ()

1. 서 론

상장지수펀드(ETF)는 특정 지수를 추종하는 인덱스 펀드를 거래소에 상장시켜 주식처럼 거래할 수 있도록 만든 펀드이다. 특정 지수를 추종함으로써 ETF는 해당 지수의 구성 종목 전체를 조금씩 매수하는 것과 같은 분산 투자 효과를 보인다. 따라서, 위험도가 낮고 운용보수가 낮다는 특징을 가진다[1]. 이러한 장점으로 인해 ETF 기반 포트폴리오(ETF Managed Portfolio)라는 전략에도 사용된다.

다양한 예측 방법들이 ETF를 활용한 자산 배분 전략 설계에 적용되고 있으나, 과거 데이터에 의존하거나 주관적인 추정치를 사용하기 때문에 예측력이 낮다는 한계점을 지닌다. 최근에는 이러한 한계를 극복할 수 있는 인공지능 기반 방법들이 개발되고 있다.

다양한 인공지능 모델 중 주로 활용되는 것은 LSTM[2], GRU[3] 등의 시계열 기반 인공지능망이다. 시계열 기반 인공지능망은 해당 시점의 자료뿐 아니라 이전 시점의 자료까지 함께 활용하는 방식으로 시간적 패턴을 반영한다. 시계열 기반 인공지능망은 우수한 예측 성능을 보였으며[4], 어텐션 메커니즘 등이 적용되어 성능이 고도화되고 있다[5].

시계열 기반 인공지능망 모델들이 과거 가격 정보들로부터 시간적 패턴을 효과적으로 학습하는 방법이지는 않지만, 서로 다른 종목들의 연관 관계를 반영하지 못한다는 한계점이 있다. 특히, ETF는 추정 지수에 포함된 다양한 구성 종목에 대한 정보를 내포하고 있으며, 다양한 구성 종목 사이의 복잡한 관계는 서로 다른 ETF 사이의 연관 관계로 이어진다. ETF의 방향성을 정확하게 예측하기 위해서는, 이러한 서로 다른 ETF 간의 연관 관계를 활용하여야 한다.

이를 위해 본 연구에서는 ETF 방향성 예측을 위해 ETF 간의 연관 관계가 반영된 그래프를 추론하고 이를 활용하는 그래프 구조 학습 기반 신경망 모델을 제안한다. 제안 모델은 그래프 구조 학습 방법론을 통해 각 ETF를 정점으로 가지는 그래프를 추론한다. 이후, 추론된 그래프와 시계열 모델로부터 얻은 ETF 임베딩을 입력으로 그래프 신경망을 수행하여, 각 ETF의 상승, 보합, 하락 확률을 예측한다. 제안 모델의 그래프 구조 학습 과정, ETF 임베딩 과정, 그리고 ETF 가격 방향성 예측 과정은 종단 간(End-to-End)으로 동시에 학습될 수 있다는 장점이 있다. 실험을 통해, 개별 ETF의 정보만 사용하는 시계열 모델 대비 제안 모델이 더 우수한 성능 보임을 확인하였다.

본 논문의 구성은 다음과 같다. 2장에서는 관련 연구 및 용어, 그리고 ETF 가격 방향성 예측을 위한 시계열 기반 방법론들에 관해 설명한다. 3장에서는 제안한 그래프 구조 학습 기반 신경망을 설명한다. 이후, 4장에는 검증을 위해 수집한 ETF 데이터셋 소개 및 제안 방법의 우수성을 평가한다. 마지막으로 5장에서 결론을 맺는다.

2. 배경지식

본 장에서는 본 논문에서 사용되는 용어들에 관해 설명하고, 관련된 선행 연구를 소개한다.

2.1 용어 설명

본 논문의 3장과 4장에서 빈번하게 사용되는 용어 및 표기를 표 1에 정리하였다.

Symbols	Definitions
N	Number of ETFs
T	Time period of input price features
F^S	Number of ETF attributes
F^P	Dimension of price features
$X^S \in R^{N \times F^S}$	Attributes of ETFs
$X^P \in R^{T \times F^P}$	Price features of each ETF
$A \in R^{N \times N}$	Adjacency matrix of the ETF graph

표 1 표기 및 정의

Table 1 Symbols and definitions

2.2 관련 연구

ETF 가격 방향성 예측은 주어진 시계열 데이터에 대한 미래를 예측하는 문제로 볼 수 있다. 시계열 데이터 예측을 위한 연구는 오랜 역사를 가지며, 대표적인 방법으로는 이동평균 또는 계절성과 같은 패턴을 활용하는 방법[6, 7] 등이 있다. 최근에는 심층학습 기술 기반 시계열 예측 방법론[2, 3, 4, 8, 9, 10, 11]들도 개발되어 활용되고 있다.

ARIMA(Auto Regressive Integrated Moving Average)[6]는 대표적인 시계열 예측 모델 중 하나로, 현재와 이전 값 사이의 관계를 auto regressive 및 moving average 구성 요소와 차분을 결합하는 방식으로 예측하는 모델이다. 이 모델은 시간 의존성, 추세, 그리고 계절성을 지니는 시계열 데이터에 대해 특히 정확한 예측을 수행하는 것으로 알려져 있다.

Exponential Smoothing[7] 역시 대표적인 방법 중 하나로, 과거 관찰에 기하급수적으로 감소하는 가중치를 할당하여 데이터의 기본 패턴을 포착하고 모델링하도록 설계된 시계열 예측 방법이다. 과거 관측치에 서로 다른 가중치를 부여하며, 특히 최근 관측치에 더 높은 가중치를 부여하는데, 이는 최근 데이터가 향후 시계열 방향성에 더 큰 영향을 미친다는 가정을 반영한 것이다. 이 방법론 또한 추세와 계절성을 지니는 데이터에 대해 특히 정확한 예측을 수행하는 것으로 알려져 있다.

위 두 방법은 효과적으로 추세, 계절성 등의 단순한 패턴을 포착할 수 있다. 하지만, 복잡한 시간적 패턴을 포착하는 능력에는 한계가 있다. 또한, 모델을 사용하기 위한 다양한 인자들을 조율하기 어렵다는 단점을 지닌다.




그림 1 제안 방법 개요도

Fig. 1. An overview of the proposed method

LSTM(Long Short-Term Memory)[2]은 순환 신경망의 한 종류로, 시계열 데이터의 장기 및 단기 의존성을 포착하고 반영하는 데 특화된 구조를 갖는다. 기존 순환 신경망 모델 대비, LSTM은 긴 시계열 데이터를 효과적으로 학습할 수 있음이 알려져 있다.

GRU(Gated Recurrent Unit)[3]는 LSTM과 마찬가지로 장단기 의존성을 감지하고 처리할 수 있는 모델이다. LSTM보다 더 간결한 구조를 가지고 있어, 빠르게 학습할 수 있다는 장점이 있다.

Attention LSTM[5]은 기존 LSTM에 어텐션 메커니즘을 결합하여 입력 시계열의 각 부분에 서로 다른 가중치를 할당하여 모델이 스스로 중요한 정보에 더 집중할 수 있도록 만든 모델이다. 각 입력 단계에서 어텐션 기반 가중치가 동적으로 계산되기 때문에 각 시점마다 중요한 정보를 강조하여 학습할 수 있으며, 일반적으로 LSTM보다 우수한 성능을 보이는 것으로 알려져 있다.

DTML[14]은 개별 주식의 방향성 예측을 위한 방법론으로 Attention LSTM을 활용하였다. 즉, 주식 간 상관관계를 반영하기 위하여 어텐션 기술을 사용한다.

ETF의 가격 방향성 예측을 위해서, 기계학습기법 중 하나인 랜덤 포레스트를 활용한 사례가 있다[15]. 해당 방법은 ETF의 다양한 정보를 사전 정의한 방법으로 인코딩해야 한다는 제약이 있으며, 선행 시간이 증가함에 따라, 예측 성능이 빠르게 감소하는 단점이 있다.

본 연구에서처럼 그래프를 시계열 예측의 활용하는 사례로는 교통 예측[16]이 있다. 해당 연구에서는 이미 주어진 도로 네트워크를 그래프 형태의 입력으로 사용하였다는 점에서, 그래프를 학습하여 사용하는 제안 방법과 차이가 있다.

3. 제안 방법

본 장에서는 논문에서 제안하는 ETF 방향성 예측을 위한 그래프 구조 학습 기반 신경망에 대해 설명한다. 제

안 방법의 개요도는 그림 1과 같다. 제안 방법은 ETF의 가격 정보(ETF Price Information)와 ETF의 섹터 정보(ETF Sector Information)를 이용하여 그래프 구조 학습 방법을 통해 ETF 그래프를 추론하는 과정(3장 1절), ETF 가격 정보로부터 Attention LSTM을 통해 ETF 가격 정보 임베딩을 추론하는 과정(3장 2절), 추론한 ETF 그래프와 가격 정보 임베딩으로부터 그래프 합성곱 신경망(Graph Convolutional Network; GCN)을 통해 ETF 가격 방향성을 예측하는 과정(3장 3절)으로 구성되어 있다. 추가적으로 ETF 그래프의 학습을 돕기 위해 정규화 역할로 노이즈제거 오토인코더(Denoising Autoencoder)를 사용하였다(3장 4절). 노이즈제거 오토인코더는 일부를 0으로 마스킹한 ETF 속성을 입력으로 하였을 때, 이를 복원해내는 것을 목표로 학습된다.

3.1 그래프 구조 학습 모델

그래프 구조 학습 모델은 N 개의 ETF들의 섹터 정보와 가격 정보로부터 얻어진 ETF 속성(ETF Attributes)으로부터 연관된 ETF를 간선으로 연결하는 ETF 그래프를 생성하는 것을 목표로 한다. 본 모델의 구조는 그림 2에서 볼 수 있다.




그림 2 그래프 구조 학습 모델 구조

Fig. 2 The architecture of the graph structure learning model

그래프 구조 학습 모델에서 ETF 그래프를 생성하는 과정은 (1) ETF 섹터 정보와 가격 정보로부터 ETF 속성을 구성하는 과정, (2) ETF 속성으로부터 ETF 임베딩을 얻는 과정, (3) ETF 임베딩을 기반으로 ETF 간 유

사도를 산출하는 과정, (4) 유사도로부터 그래프를 추론하는 과정으로 구성되어 있다.

먼저 각 ETF의 중요한 정보들을 담고 있는 ETF 속성 벡터를 구성하기 위해, 가격 및 섹터 정보를 전처리 및 벡터화한다. 이 과정을 모든 ETF에 대해 수행하여 ETF 속성 행렬($X^S \in \mathbb{R}^{N \times F^S}$)을 구성한다. 보다 상세한 설명은 데이터셋과 함께 4장 1절에서 소개한다.

ETF의 입력 정보를 반영한 ETF 속성 행렬($X^S \in \mathbb{R}^{N \times F^S}$)로부터 다층 퍼셉트론(Multi Layer Perceptron; MLP)을 통해 ETF의 임베딩 행렬($H^S \in \mathbb{R}^{N \times D}$)을 얻는다. 이때, N 은 ETF의 수이며, D 는 다층 퍼셉트론을 통해 인코딩된 ETF 임베딩의 차원으로 하이퍼파라미터이다. 제안 방법의 다층 퍼셉트론은 두 개의 계층(Layer)로 구성되어 있으며, 첫 번째 계층 이후에 비선형 활성화 함수(Activation Function)로 ReLU 함수를 사용한다.

획득된 ETF의 임베딩 간의 코사인 유사도(Cosine Similarity)를 산출하여 ETF 간의 유사도를 계산한다. 코사인 유사도는 임베딩 사이의 유사도를 산출하는 방법 중 하나로 연산이 간단하며 미분이 가능하다는 장점이 있다. 각 ETF로부터 유사도 기준 상위 K(Top K)개 ETF를 간선으로 연결하여 ETF 그래프를 구성한다. 이는 그래프의 희소성 성질을 만족하기 위함이며 이때 K는 하이퍼파라미터이다. 간선의 가중치로는 앞서 계산한 유사도를 사용한다.

3.2 Attention LSTM 기반 가격 정보 임베딩

제안 모델은 ETF 가격 정보로부터 ETF 가격 정보 임베딩을 얻기 위한 용도로 Attention LSTM을 활용한다. 이 임베딩은 3장 1절에서 추론한 ETF 그래프와 함께 추후 그래프 합성곱 신경망의 입력으로 활용된다. ETF의 가격 정보 임베딩을 얻기 위한 Attention LSTM의 구조는 그림 3과 같다.



그림 3 Attention LSTM 구조

Fig. 3 The architecture of Attention LSTM

Attention LSTM은 시계열 데이터를 위한 모델로서 각 ETF의 특정 일 수(T)만큼의 가격 정보($X^P \in \mathbb{R}^{N \times F^P}$)를 입력으로 사용한다. 주어진 입력 X^P 는 단일 계층 퍼셉트론으로 구성된 속성 변환(Feature Mapping) 과정을 거친다(수식 (1)).

$$h^{FM} = \sigma(W^{FM}X^P + b^{FM}) \quad (1)$$

이때, $W^{FM} \in \mathbb{R}^{F^P \times U}$, $b^{FM} \in \mathbb{R}^U$ 는 학습 변수이며, σ 는 활성

함수이다. U 는 ETF 임베딩의 차원으로 하이퍼파라미터이다. 속성 변환을 거친 $h^{FM} \in \mathbb{R}^{T \times U}$ 는 LSTM을 통해 시계열 정보를 반영한 임베딩 $h^{LSTM} \in \mathbb{R}^{T \times U}$ 으로 변환되며, 이후 h^{LSTM} 의 각 행에 셀프 어텐션(Self Attention)[12]을 수행하여 개별 ETF의 최종 임베딩($h^P \in \mathbb{R}^U$)을 얻어낸다. 본 과정은 수식 (2)와 같다.

$$h^P = \sum_{i=1}^N \alpha_i h_i^{LSTM} \quad (2)$$

이때, α 는 셀프 어텐션을 위해 각 일자에 할당된 가중치이며, h^{LSTM} 으로부터 수식(3)을 사용하여 산출된다.

$$\alpha = \text{softmax}(W_2^\alpha \sigma(W_1^\alpha h^{LSTM} + b_1^\alpha) + b_2^\alpha) \quad (3)$$

이때, $W_1^\alpha \in \mathbb{R}^{U \times U}$, $b_1^\alpha \in \mathbb{R}^U$, $W_2^\alpha \in \mathbb{R}^{U \times 1}$, $b_2^\alpha \in \mathbb{R}^1$ 는 학습 변수이다. 본 과정을 각 ETF에 대해 수행하여 ETF 가격 정보 임베딩 행렬($H^P \in \mathbb{R}^{N \times U}$)을 구성한다.

3.3 GCN 기반 ETF 가격 방향성 예측

그래프 구조 학습 모델(3장 1절)로부터 얻은 ETF의 그래프($A \in \mathbb{R}^{N \times N}$)와 Attention LSTM(3장 2절)으로부터 얻은 ETF의 가격 정보 임베딩($H^P \in \mathbb{R}^{N \times U}$)을 입력으로 그래프 합성곱 신경망(Graph Convolutional Network; GCN)을 사용하여 ETF의 가격 방향성을 예측한다. 해당 과정에 대한 구조는 그림 4와 같다.




그림 4 그래프 합성곱 신경망 기반
ETF 가격 방향성 예측 모델 구조

Fig. 4 The architecture of the ETF price movement prediction model based on GCN

그래프 합성곱 신경망은 두 개의 계층으로 이루어져 있으며, 첫 번째 계층에서는 비선형 활성화 함수로 tanh 함수가 사용된다. 두 번째 계층에서는 소프트맥스(Softmax)가 사용되며, 각 ETF의 가격 방향성인 상승, 보합, 하락 확률($O \in \mathbb{R}^{N \times 3}$)을 나타내는 3차원 벡터를 출력한다. 그래프 합성곱 신경망은 수식 (4)와 같다.

$$O = \text{softmax}(\hat{A}(\tanh(\hat{A}H^P W_1^{GCN} + b_1^{GCN})) W_2^{GCN} + b_2^{GCN}) \quad (4)$$

이때, $W_1^{GCN} \in \mathbb{R}^{U \times U}$, $b_1^{GCN} \in \mathbb{R}^U$, $W_2^{GCN} \in \mathbb{R}^{U \times 3}$, $b_2^{GCN} \in \mathbb{R}^3$ 는 학습 변수이며, $\hat{A} = D^{-1/2} A D^{-1/2}$ 는 정규화된 ETF 인접행렬이다. D 는 각 대각 성분이 ETF 인접행렬의 연결

성(Degree)인 대각행렬로 $D_{ii} = \sum_{j=1}^N A_{ij}$ 를 만족한다.

3.4 Denoising Autoencoder 기반 정규화

다양한 그래프 구조 학습 방법들[13, 14, 15]에서 그래프 구조를 효과적으로 학습하기 위해 정규화 과정을 추가적으로 사용한다. 제안 방법에서는 종단 간(End-to-End) 학습 방법에 적합하면서 효과적으로 그래프 구조 학습을 도울 수 있는 노이즈제거 오토인코더(Denoising Autoencoder)[14]를 해당 용도로 사용한다.

노이즈제거 오토인코더는 그래프 구조 학습 모델의 입력인 ETF들의 속성($X^S \in R^{N \times F^S}$)의 일부를 임의로 0으로 마스킹한 뒤, 이를 복원하는 것을 목표로 한다(3장 5절). 해당 모델의 인코더와 디코더로는 그래프 합성곱 신경망을 사용하며, 이를 위한 그래프는 그래프 구조 학습 모델로부터 산출된 ETF 그래프(3장 1절)를 사용한다. 노이즈제거 오토인코더의 출력은 정규화 이외의 다른 용도로는 사용하지 않는다.

3.5 학습 과정

제안 방법을 학습하기 위해서는 ETF의 섹터 정보, 특정 일자(T)만큼의 가격 정보, 그리고 상승, 보합, 하락에 대한 레이블 정보가 필요하다. 위 정보들을 입력으로, 두 가지 손실 함수를 사용하여 제안 모델을 학습한다.

첫 번째는 상승, 보합, 하락 확률에 대한 크로스 엔트로피(Cross Entropy)이다. 제안 모델로부터 얻은 ETF 가격 방향성 확률 벡터(ETF Price Movement Probability Vector) $O \in R^{N \times 3}$ 와 정답 레이블 $Y \in R^{N \times 3}$ 와의 크로스 엔트로피는 수식 (5)와 같다.

$$L_{CE} = -\frac{1}{N} \sum_{n=1}^N \sum_{m=1}^3 Y_{nm} \log(O_{nm}) \quad (5)$$

두 번째 손실 함수는 정규화를 위한 노이즈제거 오토인코더의 복원 손실 함수이다. 복원 손실 함수는 평균 제곱 오차(Mean Squared Error)를 사용하였으며 0으로 마스킹이 수행된 성분에 대해서만 산출된다. 해당 손실 함수의 수식 (6)과 같다.

$$L_{MSE} = -\frac{1}{N} \sum_{n=1}^N \sum_{m=1}^S 1_{nm} (X_{nm}^s - \bar{X}_{nm}^s)^2 \quad (6)$$

이때, $\bar{X}^s$ 는 노이즈제거 오토인코더의 출력인 복원 ETF 속성이며, 1_{nm} 은 지시자로서 n 행 m 열 성분이 0으로 마스킹이 되었다면 1, 아닌 경우 0을 갖는다.

제안 모델은 위 두 손실 함수의 합을 최소화하는 것을 목표로 학습된다. 구체적으로는 수식 (7)과 같으며 λ 는 정규화 하이퍼파라미터로 양의 실수이다.

$$L_{Total} = L_{MSE} + \lambda L_{CE} \quad (7)$$

L_{MSE} 를 최소화할 때 그래프 구조 학습 모델과 노이즈제거 오토인코더의 학습 파라미터가 갱신된다. 또한, L_{CE}

를 최소화할 때 그래프 구조 학습 모델과 Attention LSTM, 그리고 ETF 가격 방향성 예측을 위한 그래프 합성곱 신경망의 학습 파라미터가 갱신된다. 옵티마이저(Optimizer)로는 Adam [16]을 사용하였다.

4. 성능 평가

본 장에서는 ETF 방향성 예측을 위한 그래프 구조 학습 기반 신경망을 사용한 실험 결과를 설명한다.

4.1 데이터셋

본 연구를 위해 2016년부터 2022년까지의 89개 ETF의 가격을 포함한 다양한 정보들을 수집하여 사용하였다. 학습, 검증, 그리고 시험을 위해 수집된 데이터는 약 2년 9개월을 학습, 3개월을 검증, 1년을 시험에 사용할 수 있도록 나누었으며, 시험으로 사용하는 데이터를 2019년, 2020년, 2021년, 2022년으로 설정하여 총 4가지 데이터셋을 생성하여 사용하였다. 데이터셋 별 자세한 학습, 검증, 시험 기간을 표 2와 같다.

No.	Training Period	Validation Period	Test Period	Rising, Falling, Stable Ratios
1	2019.01.02.	2021.10.01.	2022.01.03.	49%,
	-	-	-	39%,
2	2021.09.30.	2021.12.30.	2022.12.29	12%
	(33 months)	(3 months)	(12 months)	
3	2018.01.02.	2020.10.05.	2021.01.04.	51%,
	-	-	-	38%,
4	2020.09.29.	2020.12.30.	2021.12.29.	11%
	(33 months)	(3 months)	(12 months)	
5	2017.01.02.	2019.10.01.	2020.01.02.	48%,
	-	-	-	42%,
6	2019.09.30	2019.12.30.	2020.12.30.	10%
	(33 months)	(3 months)	(12 months)	
7	2016.01.04.	2018.10.04.	2019.01.02.	49%,
	-	-	-	41%,
8	2018.09.28	2018.12.28.	2019.12.30.	10%
	(33 months)	(3 months)	(12 months)	

표 2 데이터셋 별 학습, 검증, 시험 기간

Table 2 Training, validation, and test periods for each dataset

3장 1절의 그래프 구조 학습 모델의 입력인 ETF 속성($X^S \in R^{N \times F^S}$)은 ETF의 가격 정보와 섹터 정보로부터 얻어진다. 먼저 ETF 가격 정보를 반영하기 위해 각 ETF에 대해 일 단위로 다음과 같은 10가지 특성값들을

계산하여 사용하였다.

- $\frac{ETF\text{의 시가}}{ETF\text{의 종가}} - 1$
 - $\frac{ETF\text{의 고가}}{ETF\text{의 종가}} - 1$
 - $\frac{ETF\text{의 저가}}{ETF\text{의 종가}} - 1$
 - $\frac{ETF\text{의 종가}}{ETF\text{의 전날 종가}} - 1$
 - 5, 10, 15, 20, 25, 30일 이동평균
- (예: 5일 이동평균 = $\frac{\text{이전 5일간 ETF 종가 평균} - 1}{ETF\text{의 종가}}$)

위 10가지 특성값들에 대해 해당 일자 및 과거 T 일 동안의 최댓값 및 평균값을 산출하여, 각 ETF마다 총 20개의 특성값으로 이루어진 벡터를 형성한다.

ETF의 섹터 정보를 반영하기 위해 범주형 정보인 ETF의 섹터 정보에 대해 원-핫 인코딩(One-Hot Encoding)을 수행하여 벡터를 형성하였다. 이때, 각 ETF는 메인섹터와 서브섹터 두가지 섹터 정보를 가지고 있으며, 각각 6종류, 31종류로 분류된다. 두 메인섹터, 서브섹터 정보를 각각 원-핫 인코딩하여 길이 6과 31인 벡터를 형성한 뒤 이를 병합(Concatenation)하여 하나의 벡터로 섹터 정보를 인코딩하였다.

위 방법으로 형성된 ETF의 가격 정보 벡터(길이 20)와 섹터 정보 벡터(길이 37)을 병합하여 ETF의 속성 벡터(길이 57)를 얻는다.

3장 2절의 Attention LSTM의 입력인 개별 ETF 가격 정보는 위 설명한 10가지 가격 특성값을 사용하였다.

각 ETF의 상승, 보합, 하락 예측값은 해당 일자로부터 한 달 뒤 종가가 3% 이상 올랐을 경우 상승, 3% 이상 하락했을 경우, 하락, 그 외는 보합으로 설정하였다. 이는 거래 수수료를 반영하여 산정한 기준이다.

4.2 평가지표 및 비교 방법론

제안 방법 및 비교 대상을 평가하기 위해서 ETF 가격 방향성인 상승, 보합, 하락에 대한 정확도(Accuracy) 및 Macro F1 Score를 산출하였다.

제안 방법을 비교하기 위해 시계열 기반 심층학습 모델들과 제안 방법의 변형 모델을 사용하여 실험을 진행하였다. 각 방법에 대한 설명은 아래와 같다.

- LSTM: LSTM은 대표적인 시계열 기반 심층학습 모델이다. LSTM의 입력으로는 ETF의 가격 정보들을 사용하였으며, 최종 임베딩의 차원을 3으로 설정하고, 소프트맥스(Softmax)를 거쳐 제안 방법과 같이 상승, 보합, 하락 확률을 예측할 수 있도록 설계하였다.
- Attention LSTM: Attention LSTM은 LSTM에 어텐션 메커니즘을 적용시킨 방법으로 각 시점마다 중요한 시간적 정보를 적응적(Adaptive)으로 반영한다는 특징이 있다. 세부 구조는 LSTM과 동일하게 설계하였다.

제안 방법의 하이퍼파라미터인 임베딩 차원 D, U 는 16으로, ETF 구성 시의 K 는 10으로 설정하였다. 4장 1절에서 설명하였듯이 가격 정보는 총 $T=15$ 일에 해당하는 정보를 사용하였다. 제안 모델 학습을 위한 학습률(Learning Rate)는 0.01, 손실 함수 간의 정규화 파라미터 λ 는 [0.1, 1, 5, 10] 중 격자 탐색(Grid Search)를 통해 선택하여 사용하였다. 모든 실험은 5번 반복하여 평균을 계산하였으며, 표준편차와 함께 제시하였다.

4.3 실험 결과

제안 방법 및 비교 방법론들에 대한 정확도, Macro F1 Score 실험 결과는 표 3, 4와 같다. 제안 방법은 서로 다른 기간에 대해 학습, 검증, 시험을 수행한 서로 다른 4개의 데이터셋에 대해 정확도와 F1 Score 모두 높은 성능을 달성함을 확인할 수 있었다. 제안 방법은 개별 ETF 가격 정보들만 사용하는 다른 비교 방법 대비 평균적으로 정확도 기준 7.62%, F1 Score 기준 2.47% 높은 성능을 보였다. 이는 서로 다른 ETF의 상호관계를 반영한 것이 성능향상에 기여했음을 의미한다.

4.4 제거 연구

본 절에서는 제안 방법에 대한 제거 연구(Ablation Study)를 수행한다. 이를 위해 제안 방법의 두가지 변형을 고려하였다.

- Ours-naïve: 제안 모델의 변형으로 ETF 그래프를 그래프 구조 학습이 아닌 규칙 기반 방법으로 생성하여 사용하는 방법이다. 구체적으로 ETF 속성 간 코사인 유사도가 0.9 이상인 ETF끼리 간선으로 연결하여 그래프를 구성하였다. 역치 값으로 0.9를 사용하여 얻은 그래프는, 제안 방법을 통해 학습한 ETF 그래프(4장 1절)와 유사한 밀집도(Density)를 갖는다. ETF 그래프를 따로 추론하지 않기 때문에 노이즈제거 오토인코더 기반의 정규화 과정 또한 수행하지 않는다.
- Ours-woReg: 제안 모델의 변형으로 그래프 구조 학습 방법을 사용할 때 정규화(3장 4절)를 위한 노이즈제거 오토인코더를 사용하지 않은 방법이다.
- Ours-woPrice: 제안 모델의 그래프 구조 학습을 위한 입력인 ETF 속성(ETF Attribute)을 구성할 때, 가격 정보 없이 섹터 정보만 사용한 방법이다.
- Ours-woSector: 제안 모델의 그래프 구조 학습을 위한 입력인 ETF 속성(ETF Attribute)을 구성할 때, 섹터 정보 없이 가격 정보만 사용한 방법이다.

실험 결과는 표 5, 6과 같다. 실험에서 확인할 수 있듯이 제거 연구에서 고려하는 변형 방법들보다 제안 방법이 더 우수한 성능을 보였다. 이는, 제안 방법에서 사용하는 그래프 구조 학습 기반 그래프 추론이 효과적으로 동작하고 있음을 의미한다. 그리고 정규화 목적으로 추가한 노이즈제거 오토인코더도 제안 모델의 성능향상에 기여함을 의미한다. 또한, 그래프 구조 학습을 위한 ETF

	Datasets				Mean
	1	2	3	4	
LSTM	0.484±0.031	0.498±0.007	0.507±0.031	0.506±0.010	0.498±0.020
Attention LSTM	0.494±0.006	0.491±0.007	0.507±0.003	0.505±0.013	0.499±0.014
Ours	<u>0.534±0.016</u>	<u>0.511±0.008</u>	<u>0.588±0.045</u>	<u>0.514±0.015</u>	<u>0.537±0.021</u> (+7.62%)

표 3 정확도 실험 결과

Table 3 Experimental results in terms of accuracy

	Datasets				Mean
	1	2	3	4	
LSTM	0.498±0.052	0.522±0.003	0.538±0.011	0.524±0.009	0.520±0.019
Attention LSTM	0.528±0.006	0.518±0.007	0.536±0.012	0.524±0.009	0.526±0.008
Ours	<u>0.550±0.016</u>	<u>0.529±0.010</u>	<u>0.548±0.012</u>	<u>0.527±0.017</u>	<u>0.539±0.013</u> (+2.47%)

표 4 F1 Score 실험 결과

Table 4 Experimental results in terms of macro F1 score

	Datasets				Mean
	1	2	3	4	
Ours-naïve	0.499±0.020	0.485±0.014	0.592±0.025	0.478±0.017	0.488±0.019
Ours-woReg	0.522±0.008	0.521±0.013	0.597±0.068	0.495±0.032	0.531±0.030
Ours-woPrice	0.495±0.010	0.488±0.006	0.506±0.012	0.504±0.014	0.498±0.011
Ours-woSector	0.523±0.013	0.509±0.010	0.505±0.058	0.493±0.018	0.508±0.025
Ours	0.534±0.016	0.511±0.008	0.588±0.045	0.514±0.015	<u>0.537±0.021</u>

표 5 제거 연구 결과 (정확도)

Table 5 Ablation study results in terms of accuracy

	Datasets				Mean
	1	2	3	4	
Ours-naïve	0.495±0.021	0.487±0.022	0.506±0.009	0.487±0.010	0.494±0.016
Ours-woReg	0.534±0.008	0.536±0.015	0.533±0.032	0.507±0.040	0.527±0.023
Ours-woPrice	0.526±0.011	0.516±0.006	0.542±0.003	0.526±0.009	0.528±0.007
Ours-woSector	0.546±0.012	0.525±0.007	0.535±0.035	0.520±0.012	0.531±0.017
Ours	0.550±0.016	0.529±0.010	0.548±0.012	0.527±0.017	<u>0.539±0.013</u>

표 6 제거 연구 결과 (F1 Score)

Table 6 Ablation study results in terms of macro F1 score.

속성을 구성할 때, 가격 정보와 섹터 정보를 모두 사용하는 것이 성능향상에 기여함을 의미한다.

5. 결론

본 논문에서는 ETF 가격 방향성 예측을 위한 그래프 구조 학습 기반 신경망을 제안하였다. 제안 모델은 그래프 구조 학습 모델을 활용하여 ETF 가격 방향성 예측에 개별 정보만 사용하는 것이 아니라 연관된 ETF의 정보를 함께 사용할 수 있도록 설계하였다. 이를 위해 그래프 구조 학습 모델을 활용하여 ETF 그래프를 얻으며, Attention LSTM을 활용하여 가격 정보 임베딩을 얻는다. 이후 그래프 합성곱 신경망을 통해 ETF 가격 방향성을 예측한다. 추가적으로 그래프 구조를 효과적으로 학습하기 위해 노이즈제거 오토인코더 기반 정규화 방법을 사용한다. 제안 방법은 개별 정보만으로 가격 방향성을 예측하는 방법론 대비 평균적으로 정확도 기준 7.62%, F1 Score 기준 2.47% 성능향상을 보였다.

참 고 문 헌

- [1] C. S. Hur, H. C. Kang, and K. S. Eom, "Price Efficiency of Exchange-Traded Funds in Korea," *Journal of Money & Finance*, Vol. 26, No.1, pp. 39-73, 2012. (in Korean)
- [2] S. Hochreiter, and J. Schmidhuber, "Long short-term memory," *Neural Computation*, Vol. 9, No. 8, pp. 1735-1780, 1997.
- [3] K. Cho, B. Van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," *Proc. of the 2014 Conference on Empirical Methods in Natural Language Processing*, pp. 1724-1734, 2014.
- [4] D. M. Q. Nelson, A. C. M. Pereira, and R. A. de Oliveira, "Stock market's price movement prediction with LSTM neural networks," *Proc. of the International Joint Conference on Neural Networks 2017*, pp. 1419-1426, 2017.
- [5] H. Li, Y. Shen, and Y. Zhu, "Stock Price Prediction Using Attention-based Multi-Input LSTM," *Proc. of the Asian conference on machine learning 2018*, pp. 454-469, 2018.
- [6] G. E. P. Box, G. Jenkins, *Time Series Analysis: Forecasting and Control*, John Wiley & Sons, 1970.
- [7] R. B. Goodell. *Smoothing Forecasting and Prediction of Discrete Time Series*, Courier Corporation, 2004.
- [8] J. Lee, "Predicting the Upward Reversal of the Stock Market Trend based on Neural Network Learning," *Proc. of the KIISE Transactions on Computing Practices 2021*, pp. 137-144, 2021. (in Korean)
- [9] J. Yoo, Y. Soun, Y. Park, and U. Kang, "Accurate Multivariate Stock Movement Prediction via Data-Axis Transformer with Multi-Level Contexts," *Proc. of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining 2021*, pp. 2037-2045, 2021.
- [10] J. Lee, and O. Shin, "Prediction of the Return Direction of ETF Using Machine Learning," *Proc. of Symposium of the Korean Institute of communications and Information Sciences 2021*, pp. 376-377, 2021. (in Korean)
- [11] B. Yu, H. Yin, Z. Zhu, "Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting," *Proc. of the 27th International Joint Conference on Artificial Intelligence*, pp. 3634-3640, 2018.
- [12] A. Vaswani et al., "Attention is All You Need," *Advances in Neural Information Processing Systems*, Vol 33, pp 6000-6010, 2017.
- [13] W. Jin, Y. Ma, X. Liu, X. Tang, S. Wang, and J. Tang, "Graph Structure Learning for Robust Graph Neural Networks," *Proc. of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pp. 66-74, 2020.
- [14] B. Fatemi, L. El. Asri, and S. M. Kazemi, "SLAPS: Self-supervision Improves Structure Learning for Graph Neural Networks," *Advances in Neural Information Processing Systems*, Vol 34, pp. 22667-22681, 2021.
- [15] C. Shang, J. Chen, and J. Bi. "Discrete Graph Structure Learning for Forecasting Multiple Time Series," *Proc. of International Conference on Learning Representations 2021*, 2021.
- [16] D. P. Kingma, J. Ba, "Adam: A Method for Stochastic Optimization," *Proc. of International Conference on Learning Representations 2015*, 2015.